

GAN

Abstract

- 적대적 학습을 통해 생성 모델을 추정하는 프레임워크 제안
- Generative Model (G)와 Discriminative Model (D) 학습
 - G: Training data를 분포를 모사하는 모델
 - D: 주어진 이미지가 G로 부터 생성된 이미지인지, 실제 이미지인지 판단하는 모델

Introduction

- 생성자 G와 판별자 D의 적대적 학습을 수행한다
 - 생성자는 위조 지폐를 만드는 위조 지폐범에, 판별자는 위조 지폐를 찾으려고 하는 경찰에 비유할 수 있다.
 - 판별자가 G가 생성한 이미지와 실제 이미지를 구별하지 못할 때까지 학습하는 것을 목표로 한다.

Adversarial nets

- 모델은 Multi-layer Perceptrons 을 따른다
- Objective Function

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

- 첫 번째 항: 실제 데이터 \mathbf{x} 를 D의 입력으로 넣었을 때 나오는 값에 로그를 취한 값
- 두 번째 항: 가짜 데이터 \mathbf{z} 를 G의 입력으로 넣었을 때 나오는 값을 D의 입력으로 넣은 후, 해당 값을 1에 빼고 로그를 취한 값

- $D(G(z))$: z 로부터 G 가 생성한 이미지를 D 가 가짜 이미지라고 판별할 확률
- D 는 objective function V 를 최대화시키고자 하고, G 는 최소화 시키고자 한다.

Evaluation Metrics

- Inception Score(IS)
 - Inception 모델을 사용하여, 생성된 이미지의 품질과 다양성 측정
 - 과정
 - 생성된 이미지를 Inception Model (ImageNet과 같은 데이터셋에 대해 훈련된) 의 입력으로 넣어 분류를 수행함
 - 각각의 생성된 이미지에 대한 확률 분포를 구함
 - 아래의 식을 계산

$$IS(\mathbb{P}_g) = e^{\mathbb{E}_{\mathbf{x} \sim \mathbb{P}_g} [KL(p_{\mathcal{M}}(y|\mathbf{x}) || p_{\mathcal{M}}(y))]}$$

- Ex: 기대값
- $P(y|x)$: 이미지 x 가 주어졌을 때 클래스 y 에 속할 확률
- $p(y)$: 생성된 이미지에 대한 클래스 y 의 평균 확률
- 각 이미지가 명확하게 하나의 클래스에 잘 속하도록 생성 되었는지, 즉, 품질을 측정
- 다양한 클래스의 이미지가 생성 되었는지, 즉, 다양성 측정
- Frechet Inception Distance (FID)
 - 생성된 이미지와 실제 이미지 사이의 통계적 유사성 측정
 - Inception 모델을 통해 생성된 이미지와 실제 이미지의 Feature Map을 추출한 후, 해당 Feature Map의 평균과 공분산을 비교
 - 공식

$$d^2((m, C), (m_w, C_w)) = \|m - m_w\|_2^2 + \text{Tr}(C + C_w - 2(CC_w)^{1/2}).$$

Notations	
m	실제 데이터의 특징 평균
C	실제 데이터의 특징 공분산 행렬
m_w	생성한 데이터의 특성 평균
C_w	생성한 데이터의 공분산 행렬

- FID가 낮다는 것은 실제 이미지와 생성된 이미지가 통계적으로 유사하다는 것을 의미함
- 두 분포사이의 거리를 측정하는 것이기 때문에, 실제 데이터 분포와의 유사도를 평가할 수 있음

- References

- <https://nippleshot.github.io/2020/12/25/GANMetric.html>